

Рубежный контроль №1 по ТМО

Студент: Павел Кузнецов

Группа: ИУ5-64Б

Вариант: 12

Задача: №2

Датасет: №4 (Heart Disease Dataset)

Постановка задачи


Для варианта 12 требуется обработать пропуски в одном категориальном и одном количественном признаке, обосновать выбранные методы заполнения, построить violin plot и определить признаки, которые целесообразно использовать для дальнейшего машинного обучения.



Подготовка данных

В исходном CSV пропуски отсутствуют, поэтому они были внесены искусственно в соответствии с примечанием из задания. Для количественного признака `chol` распределение имеет положительную асимметрию (1.074), поэтому использована медиана. Для категориального признака `thal` использована мода как наиболее частое значение класса.

Признак	Пропусков внесено	Метод заполнения	Использованное значение
chol	51	median	240.0
thal	41	mode	2

Графики





Признаки для ML

Для дальнейшего обучения моделей стоит оставить все медицински интерпретируемые признаки, но приоритизировать признаки с наиболее выраженной связью с target. В данном датасете это прежде всего: oldpeak, exang, cp, thalach, ca, slope, thal, sex, age.

Признак	Корреляция с target
oldpeak	-0.438
exang	-0.438
cp	0.435
thalach	0.423
ca	-0.382

slope	0.346
thal	-0.342
sex	-0.280

Вывод

Для числового признака `chol` использовано заполнение медианой, для категориального `thal` заполнение модой. Обязательный violin plot построен, а приоритетные признаки для дальнейшего моделирования определены.