

Рубежный контроль №1 по ТМО

Студент: Павел Смит

Группа: ИУ5-64Б

Вариант: 12

Задача: №2

Датасет: №4 (Heart Disease Dataset)

Постановка задачи

Для варианта 12 требуется обработать пропуски в одном категориальном и одном количественном признаке, обосновать выбранные методы заполнения, построить violin plot и определить признаки, которые целесообразно использовать для дальнейшего машинного обучения.


Подготовка данных



В исходном CSV пропуски отсутствуют, поэтому они были внесены искусственно в соответствии с примечанием из задания. Для количественного признака `chol` распределение имеет положительную асимметрию (1.074), поэтому использована медиана. Для категориального признака `thal` использована мода как наиболее частое значение класса.

Признак	Пропусков внесено	Метод заполнения	Использованное значение
chol	51	median	240.0
thal	41	mode	2

Графики

Ниже приведены три ключевые иллюстрации: сравнение количества пропусков до и после обработки, обязательный violin plot для признака `chol` и распределение категориального признака `thal` после заполнения.





Признаки для ML

Для дальнейшего обучения моделей стоит оставить все медицински интерпретируемые признаки, но приоритизировать признаки с наиболее выраженной связью с target. В данном датасете это прежде всего: oldpeak, exang, cp, thalach, ca, slope, thal, sex, age.

Признак	Корреляция с target
oldpeak	-0.438
exang	-0.438
cp	0.435
thalach	0.423
ca	-0.382

slope	0.346
thal	-0.342
sex	-0.280

Вывод

Задача варианта 12 решена: для числового признака `chol` выбрано заполнение медианой, для категориального `thal` заполнение модой, обязательный violin plot построен, а набор приоритетных признаков для дальнейшего моделирования определен.

Источник датасета: Kaggle Heart Disease Dataset (`johnsmith88`). Для воспроизводимости в проекте использован открытый CSV-зеркальный файл.